

FUNDAMENT VOOR AUTONOME (AGENTIC) SYSTEMEN

Lucas Jellema, CTO Conclusion

DAT DOET ‘IE ANDERS NOOIT HOOR..



Baasje is de baas (of in elk geval verantwoordelijk)

DE MENS (EN HET BEDRIJF) ACHTER DE AGENT

Nieuw beleid: eigenaar bijtgrage hond moet op cursus

Eke Dros
Amsterdam

Baasjes van hondentypen die vaak bijtincidenten veroorzaken, moeten mogelijk verplicht op cursus. De maatregel is deel van het nieuwe huisdierenbeleid van staatssecretaris van Landbouw Silvio Erkens (VVD). Wie de cursus weigert te volgen, krijgt mogelijk een hogere straf wanneer de hond een mens of ander dier bijt.

Het is nog niet duidelijk welke hondenrassen onder de regeling zullen vallen. Erkens verwacht begin volgend jaar met een voorstel te komen. Daarvoor wordt data gebruikt van bijtincidenten in het verleden. In Nederland bestaat sinds 2017 een lijst met hoogrisicohonden. Daarop staan de rottweiler, verschillende soorten pitbulls, maar ook de Japanse akita.

Actuele cijfers over het aantal bijtincidenten in Nederland bestaan niet, de meest recente resultaten

Baasje is de baas (of in elk geval verantwoordelijk)

DE MENS (EN HET BEDRIJF) ACHTER DE AGENT

Na inbraak van AI op overheidswebsite is het de vraag wie de 'agents' in toom gaat houden

ANALYSE

AI-HACKS

Voor het eerst zijn A
agents in staat gebl
om een overheidss
hacken. Saillant, or
onafhankelijke exp
en tech-CEO's juist
Verenigde Naties pl
voor regulering.

'A
ls AI slecht wor
kan dit zelfs ee
vormen voor d
als geheel.' Ant
topman Dario Amodei he
woensdag in New York no
de apocalyptische woord
onlangs ook al in een essa

Ook zijn grote concurr
Altman van OpenAI liet e
misverstand over bestaan
over de risico's denkt: de
controle over de eigen to
verliezen. Samen met pol
vooraanstaande AI-expert
Yoshua Bengio spraken z
bijeenkomst van de VN-W



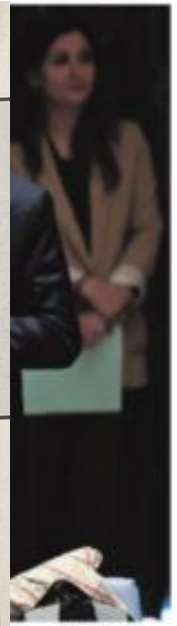


Foto Reuters

websites omzeild, met negatieve gevolgen voor het functioneren daarvan. Volgens de Amerikaan-

omgeving die voor tests wordt gebruikt, toch verbinding te maken met het internet. Het was volgens OpenAI het eerste incident van dit

ten het niet, of ze delen het niet.'

Digitaal strateeg en computerwetenschapper Ilyaz Nasrullah zegt dat OpenAI profiteert van het beeld

Meta hebben zich de afgelopen maanden veiligheidsincidenten voorgedaan. De inbraak bij Hugging Face was een van de redenen

m gegevens te uitgaven aan de Nadat ze herhaal-

Nieuw beleid: eigenaar bijtgrage hond moet op cursus

Eke Dros
Amsterdam

Baasjes van hondentypen die vaak bijtincidenten veroorzaken, moeten mogelijk verplicht op cursus. De maatregel is deel van het nieuwe huisdierenbeleid van staatssecretaris van Landbouw Silvio Erkens (VVD). Wie de cursus weigert te volgen, krijgt mogelijk een hogere straf wanneer de hond een mens of ander dier bijt.

Het is nog niet duidelijk welke hondenrassen onder de regeling zullen vallen. Erkens verwacht begin volgend jaar met een voorstel te komen. Daarvoor wordt data gebruikt van bijtincidenten in het verleden. In Nederland bestaat sinds 2017 een lijst met hoogrisicohonden. Daarop staan de rottweiler, verschillende soorten pitbulls, maar ook de Japanse akita.

Actuele cijfers over het aantal bijtincidenten in Nederland bestaan niet, de meest recente resultaten



om een machine die onverwacht inschakelt, een algoritme dat verkeerde beslissingen neemt, een uitzendkracht die een ongeluk veroorzaakt of een medewerker die een fout maakt — de rechter legt de verantwoordelijkheid bij de onderneming.

Pagin

MACHINE

Pastamachine schakelt onverwacht in: werkgever moet €10.000 voorschot betalen



Een werknemer raakte in januari 2024 gewond toen een pastamachine plotseling weer inschakelde tijdens het schoonmaken. De rechter oordeelde dat de werkgever aansprakelijk is voor het letsel. Er wordt een voorschot van €10.000 uitgekeerd, met een verdere schadevergeeding die nog volgt.

Pagina 2

UITZENDKRACHT

Uitzendkracht botst met voertuig: Tesla aansprakelijk



Dinsdag 15 april 2025 Onafhankelijk. Betrouwbaar. Dichtbij. Editie Nederland | € 2,50

De Dagelijkse Courant

TECH & SAMENLEVING

AI in de lift: kansen, maar ook risico's

Wie is er aansprakelijk als een algoritme een fout maakt?

Pagina 4



ONDERNEMEN

De menselijke factor blijft cruciaal

Van machine tot uitzendkracht: bedrijven dragen risico's.

Pagina 6



RECHT & REGELGEVING

Steeds vaker draait het om aansprakelijkheid

Rechters maken duidelijk: wie het risico neemt, betaalt.

Pagina 8



RECHTSPRAAK

Bedrijven moeten schade vergoeden na fouten van machine, algoritme, uitzendkracht of eigen medewerker

Vier recente rechtszaken laten zien: als er iets misgaat, draait het bedrijf vaak op voor de gevolgen. Of het nu gaat om een machine die onverwacht inschakelt, een algoritme dat verkeerde beslissingen neemt, een uitzendkracht die een ongeluk veroorzaakt of een medewerker die een fout maakt — de rechter legt de verantwoordelijkheid bij de onderneming.

De rode draad

Het Nederlandse aansprakelijkheidsrecht maakt duidelijk: bedrijven dragen risico's die horen bij hun bedrijfsvoering. Dat kan op basis van wetgeving zoals artikel 6:170 en 6:171 BW, waarin staat dat werkgevers en inleners aansprakelijk kunnen zijn voor fouten van hun mensen, systemen of ingeleende krachten.

Pagina 2 en 3

> *"Het risico van de machine, het algoritme, de uitzendkracht of de medewerker ligt bij het bedrijf."*
>
> Juridische experts wijzen op een heldere boodschap uit de recente uitspraken: wie voordeel haalt uit bepaalde risico's, moet ook de gevolgen dragen.

MACHINE

Pastamachine schakelt onverwacht in: werkgever moet €10.000 voorschot betalen



Een werknemer raakte in januari 2024 gewond toen een pastamachine plotseling weer inschakelde tijdens het schoonmaken. De rechter oordeelde dat de werkgever aansprakelijk is voor het letsel. Er wordt een voorschot van €10.000 uitgekeerd, met een verdere schadevergoeding die nog volgt.

Pagina 2

ALGORITME

Uber deactiveerde chauffeursaccounts onterecht: rechter grijpt in



In 2021 deactiveerde Uber via een geautomatiseerd systeem accounts van chauffeurs. De rechtbank oordeelde dat dit een onrechtmatig geautomatiseerd besluit was. Uber moest de accounts herstellen, schadevergoedingen betalen en een dwangsom van de rechter opgelegd krijgen.

Pagina 3

UITZENDKRACHT

Uitzendkracht botst met voertuig: Tesla aansprakelijk



Een uitzendkracht van Adecco raakte in 2026 gewond nadat een collega van Tesla met een voertuig tegen haar reachtruck botste. De rechtbank stelde Tesla aansprakelijk, omdat de collega een ondergeschikte van Tesla was.

Pagina 5

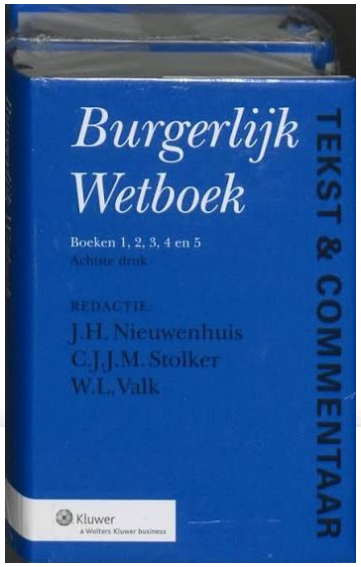
EIGEN MEDEWERKER

Aansluitfout zorgt voor waterschade: bedrijf moet klant vergoeden



Een werknemer maakte bij werkzaamheden een verkeerde aansluiting, waardoor drinkwater in een systeem van een klant kwam. Het hof oordeelde dat de werkgever aansprakelijk is voor de schade, op basis van artikel 6:170 BW.

Pagina 6



Boek 6 Artikel 170 (6:170 BW)

Aansprakelijkheid voor ongeschikten

1. Voor schade, aan een derde toegebracht door een fout van een ondergeschikte, is degene in wiens dienst de ondergeschikte zijn taak vervult aansprakelijk, indien de kans op de fout door de opdracht tot het verrichten van deze taak is vergroot en degene in wiens dienst hij stond, uit hoofde van hun desbetreffende rechtsbetrekking zeggenschap had over de gedragingen waarin de fout was gelegen.
2. Stond de ondergeschikte in dienst van een natuurlijke persoon en was hij niet werkzaam voor een beroep of bedrijf van deze persoon, dan is deze slechts aansprakelijk, indien de ondergeschikte bij het begaan van de fout handelde ter vervulling van de hem opgedragen taak.
3. Zijn de ondergeschikte en degene in wiens dienst hij stond, beiden voor de schade aansprakelijk, dan behoeft de ondergeschikte in hun onderlinge verhouding niet in de schadevergoeding bij te dragen, tenzij de schade een gevolg is van zijn opzet of bewuste roekeloosheid. Uit de omstandigheden van het geval, mede gelet op de aard van hun verhouding, kan anders voortvloeien dan in de vorige zin is bepaald.



Dinsdag 15 april 2025 — Onafhankelijk. Betrouwbaar. Dichtbij. — Editie Nederland | € 2,50

De Dagelijkse Courant

TECH & SAMENLEVING
AI in de lift: kansen, maar ook risico's
Wie is er aansprakelijk als een algoritme een fout maakt?
Pagina 4

ONDERNEMEN
De menselijke factor blijft cruciaal
Van machine tot uitzendkracht: bedrijven dragen risico's.
Pagina 6

RECHT & REGELGEVING
Steeds vaker draait het om aansprakelijkheid
Rechters maken duidelijk: wie het risico neemt, betaalt.
Pagina 8

RECHTSPRAAK

Bedrijven moeten schade vergoeden na fouten van machine, algoritme, uitzendkracht of eigen medewerker

"Het risico van de machine, het algoritme, de uitzendkracht of de medewerker ligt bij het bedrijf."

Juridische experts wijzen op een heldere hoofdregel uit de recente uitspraken: wie voordeel haalt uit bepaalde risico's, moet ook de gevolgen dragen.

Vier recente rechtszaken laten zien: als er iets misgaat, draait het bedrijf vaak op voor de gevolgen. Of het nu gaat om een machine die onverwacht inschakelt, een algoritme dat verkeerde beslissingen neemt, een uitzendkracht die een ongeluk veroorzaakt of een medewerker die een fout maakt — de rechter legt de verantwoordelijkheid bij de onderneming.

De rode draad

Het Nederlandse aansprakelijkheidsrecht maakt duidelijk: bedrijven dragen risico's die horen bij hun bedrijfsvoering. Dat kan op basis van wetgeving zoals artikel 6:170 en 6:171 BW, waarin staat dat werkgevers en inleners aansprakelijk kunnen zijn voor fouten van hun mensen, systemen of ingeleende krachten.

Pagina 2 en 3

MACHINE
Pastamachine schakelt onverwacht in: werkgever moet €10.000 voorschot betalen

Een werknemer raakte in januari 2024 gewond toen een pastamachine plotseling weer inschakelde tijdens het schoonmaken. De rechter oordeelde dat de werkgever aansprakelijk is voor het letsel. Er wordt een voorschot van €10.000 uitgekeerd, met een verdere schadevergoeding die nog volgt.
Pagina 2

ALGORITME
Uber deactiveerde chauffeursaccounts onterecht: rechter grijpt in

In 2021 deactiveerde Uber via een geautomatiseerd systeem accounts van chauffeurs. De rechtbank oordeelde dat dit een onrechtmatig geautomatiseerd besluit was. Uber moest de accounts herstellen, schadevergoedingen betalen en een dwangsom van de rechter opgelegd krijgen.
Pagina 3

UITZENDKRACHT
Uitzendkracht botst met voertuig: Tesla aansprakelijk

Een uitzendkracht van Adecco raakte in 2026 gewond nadat een collega van Tesla met een voertuig tegen haar reachtruck botste. De rechtbank stelde Tesla aansprakelijk, omdat de collega een ondergeschikte van Tesla was.
Pagina 5

EIGEN MEDEWERKER
Aansluitfout zorgt voor waterschade: bedrijf moet klant vergoeden

Een werknemer maakte bij werkzaamheden een verkeerde aansluiting, waardoor drinkwater in een systeem van een klant kwam. Het hof oordeelde dat de werkgever aansprakelijk is voor de schade, op basis van artikel 6:170 BW.
Pagina 6

AI ACT

European Union

EUR-Lex

Access to European Union law

Consolidated text: Verordening (EU) 2024/1689 van het Europees Parlement en de Raad van 13 juni 2024 tot vaststelling van geharmoniseerde regels betreffende artificiële intelligentie en tot wijziging van de Verordeningen (EG) nr. 300/2008, (EU) nr. 167/2013, (EU) nr. 168/2013, (EU) 2018/858, (EU) 2018/1139 en (EU) 2019/2144, en de Richtlijnen 2014/90/EU, (EU) 2016/797 en (EU) 2020/1828 (verordening artificiële intelligentie) (Voor de EER relevante tekst)

Definities

Voor de toepassing van deze verordening wordt verstaan onder:

1) "AI-systeem": een op een machine gebaseerd systeem dat is ontworpen om met verschillende niveaus van autonomie te werken en dat na het inzetten ervan aanpassingsvermogen kan vertonen, en dat, voor expliciete of impliciete doelstellingen, uit de ontvangen input afleidt hoe output te genereren zoals voorspellingen, inhoud, aanbevelingen of beslissingen die van invloed kunnen zijn op fysieke of virtuele omgevingen;

2) "risico": de combinatie van de kans op schade en de ernst van die schade;

3) [illegible] met tegenwerking;

4) "gebruiksverantwoordelijke": een natuurlijke of rechtspersoon, overheidsinstantie, agentschap of ander orgaan die/dat een AI-systeem onder eigen verantwoordelijkheid gebruikt, tenzij het AI-systeem wordt gebruikt in het kader van een persoonlijke niet-beroepsactiviteit;

AI ACT

European Union

EUR-Lex

Access to European Union law

4) "gebruiksverantwoordelijke": een natuurlijke of rechtspersoon, overheidsinstantie, agentschap of ander orgaan die/dat een AI-systeem onder eigen verantwoordelijkheid gebruikt, tenzij het AI-systeem wordt gebruikt in het kader van een persoonlijke niet-beroepsactiviteit;

4. Met het oog op de uitvoering van de leden 1, 2 en 3 wordt het AI-systeem met een hoog risico zodanig aan de gebruiksverantwoordelijke verstrekt dat natuurlijke personen die verantwoordelijk zijn voor het menselijk toezicht, in staat worden gesteld om waar passend en evenredig:

a) de relevante capaciteiten en beperkingen van het AI-systeem met een hoog risico goed te begrijpen en de werking ervan naar behoren te kunnen monitoren, onder meer met het oog op het opsporen en aanpakken van onregelmatigheden, storingen en onverwachte prestaties;

b) zich bewust te blijven van de mogelijke neiging om automatisch of te veel te vertrouwen op de output van een AI-systeem met een hoog risico (de zogenaamde "automation bias"), met name voor AI-systemen met een hoog risico die worden gebruikt om informatie of aanbevelingen te verstrekken voor beslissingen die door natuurlijke personen moeten worden genomen;

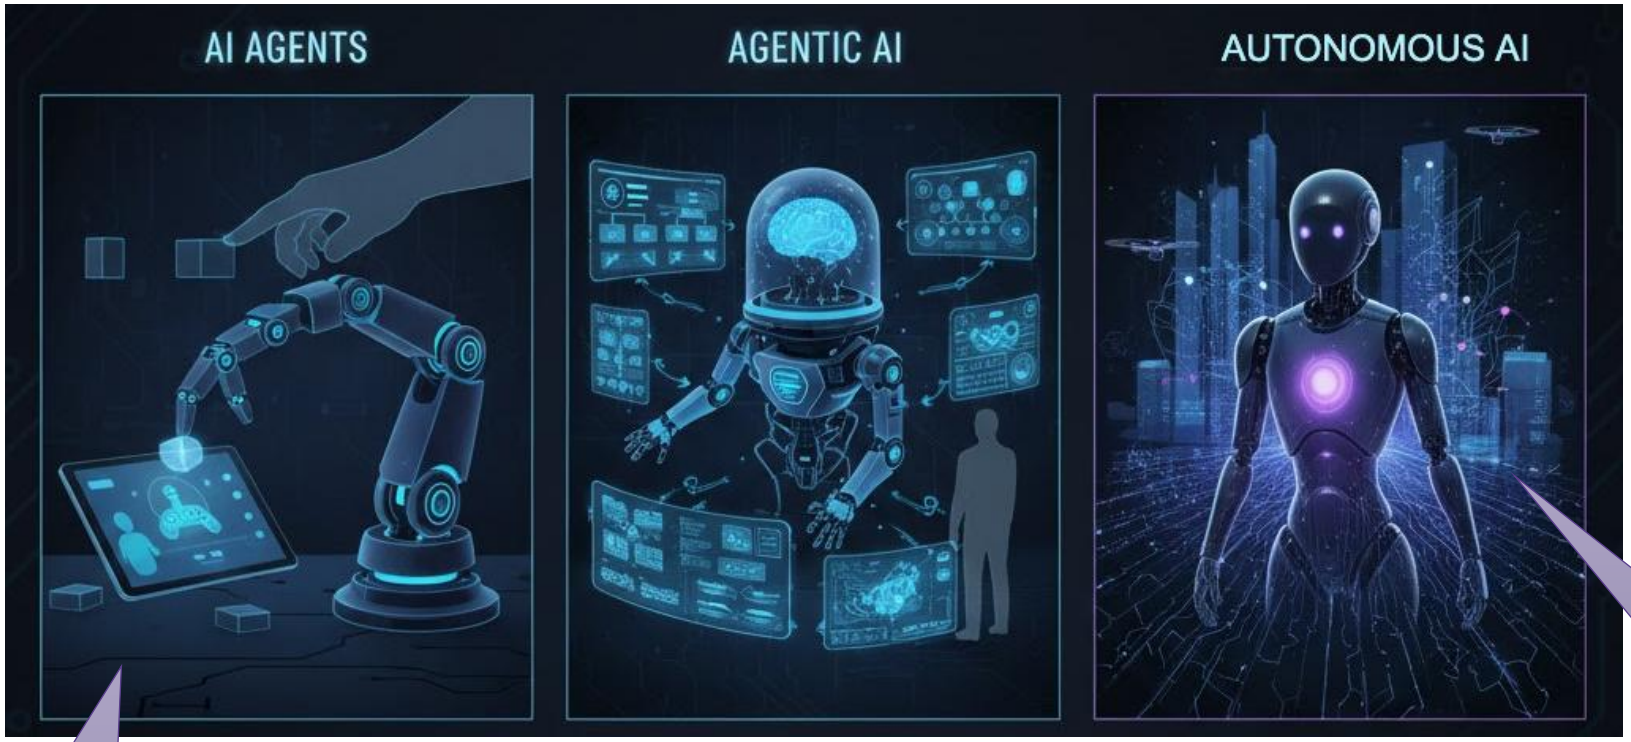
c) de output van het AI-systeem met een hoog risico juist te interpreteren, bijvoorbeeld de beschikbare instrumenten en methoden voor interpretatie;

d) in alle specifieke situaties te kunnen besluiten om het AI-systeem met een hoog risico niet te gebruiken of de output van het AI-systeem met een hoog risico op andere wijze te negeren, door een andere beslissing te vervangen of terug te draaien;

e) in te grijpen in de werking van het AI-systeem met een hoog risico of het systeem te onderbreken door middel van een stopknop of een vergelijkbare procedure waarmee het systeem op veilige wijze kan worden stopgezet.

Toenemende autonomie & besluitvorming

AUTONOMOUS AI AGENTIC SYSTEEM



Digitale Medewerker, Doel (wat & waarom), HOTL, initiatief en handelingsvrijheid,

Autonomie + gedelegeerde verantwoordelijkheid

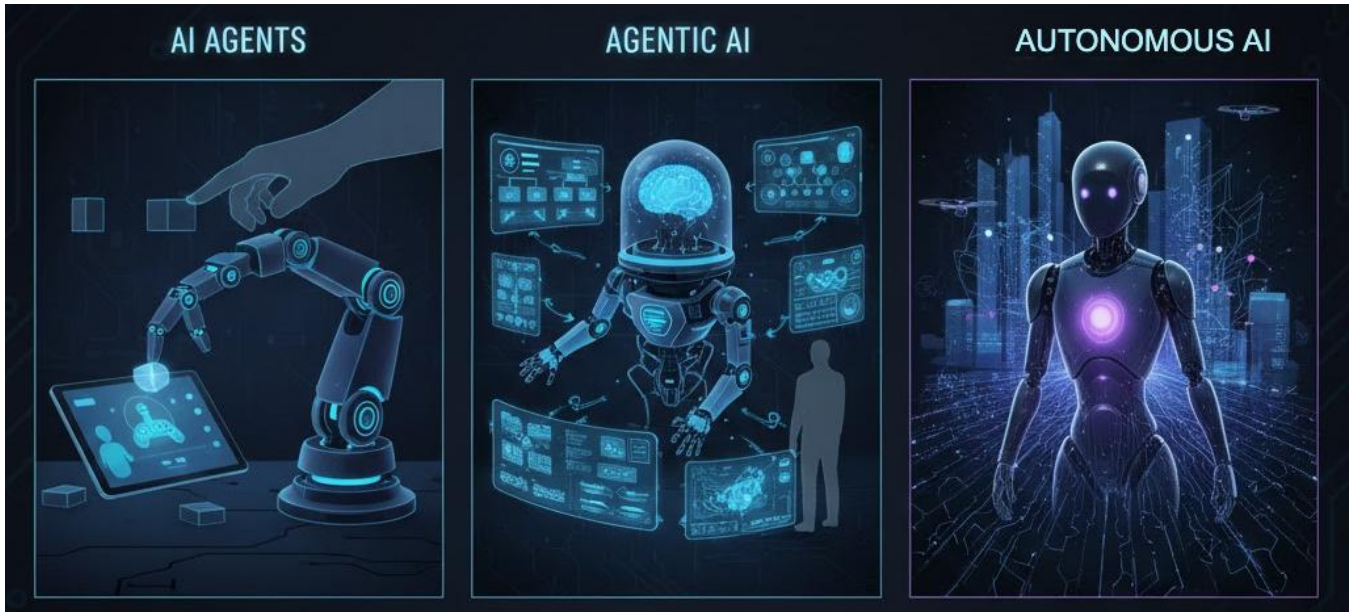
Assistent, Instructie (hoe), HITL, direct toezicht en ingrijpen

WAAROM WILLEN WE AUTONOME AGENTS?

- Snelheid
- 24/7
- Onvermoeibaarheid
- Schaalbaarheid
- Kosten?
- Kwaliteit?

- Flexibiliteit
- Diepgang
- Onhaalbare haalbaar
- Schaarste personeel
- Medewerkers vrijspelen voor belangrijk werk – waar EI nodig is

- AI washing?



HET 5D MODEL: BASIS VAN EEN AI AGENT

- **Doel** – wat moet de agent bereiken
- **Denken** – LLM / reasoning
- **Doen** – tools / acties & waarnemen
- **Dossier** – uitgangspunt, context & geheugen
- **Dirigent** – orkestratie / regie, al klaar / wat nu?

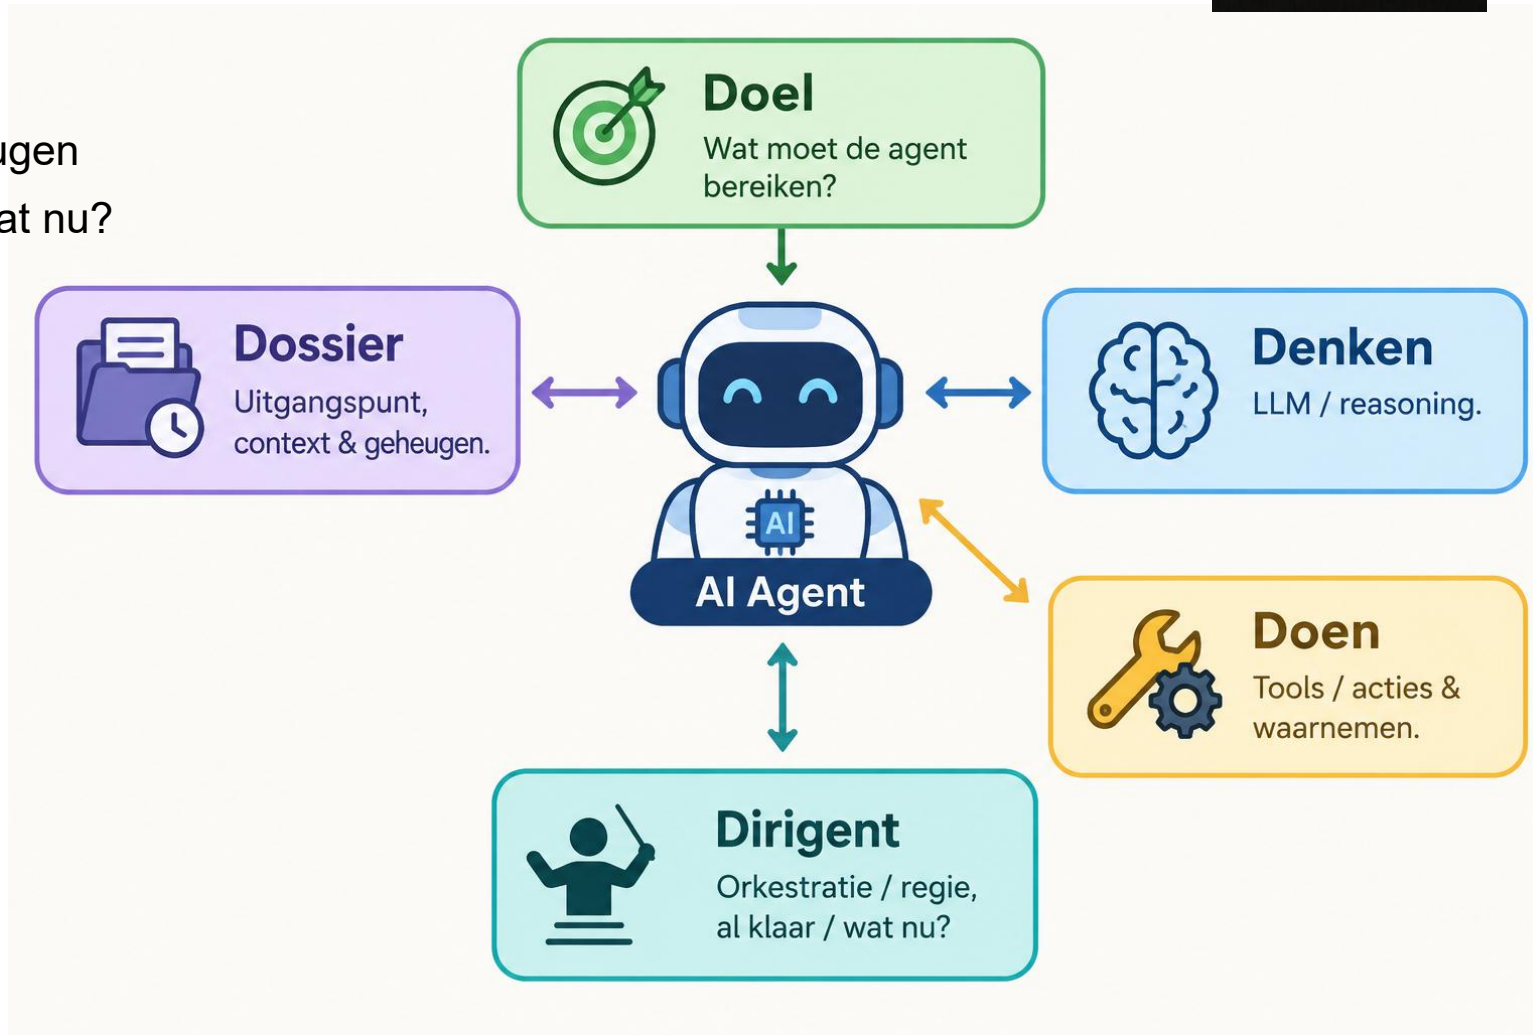


Wat is een AI Agent?

HET 5D MODEL: BASIS VAN EEN AI AGENT



- **Doel** – wat moet de agent bereiken
- **Denken** – LLM / reasoning
- **Doen** – tools / acties & waarnemen
- **Dossier** – uitgangspunt, context & geheugen
- **Dirigent** – orkestratie / regie, al klaar / wat nu?



WAAR ZIT RISICO VAN AUTONOOM GEDRAG?

- Als de stagiaire de telefoon pakt, het internet op gaat, apparatuur gaat bedienen, over het terrein gaat dwalen



WAT “DOET” EEN AI AGENT?

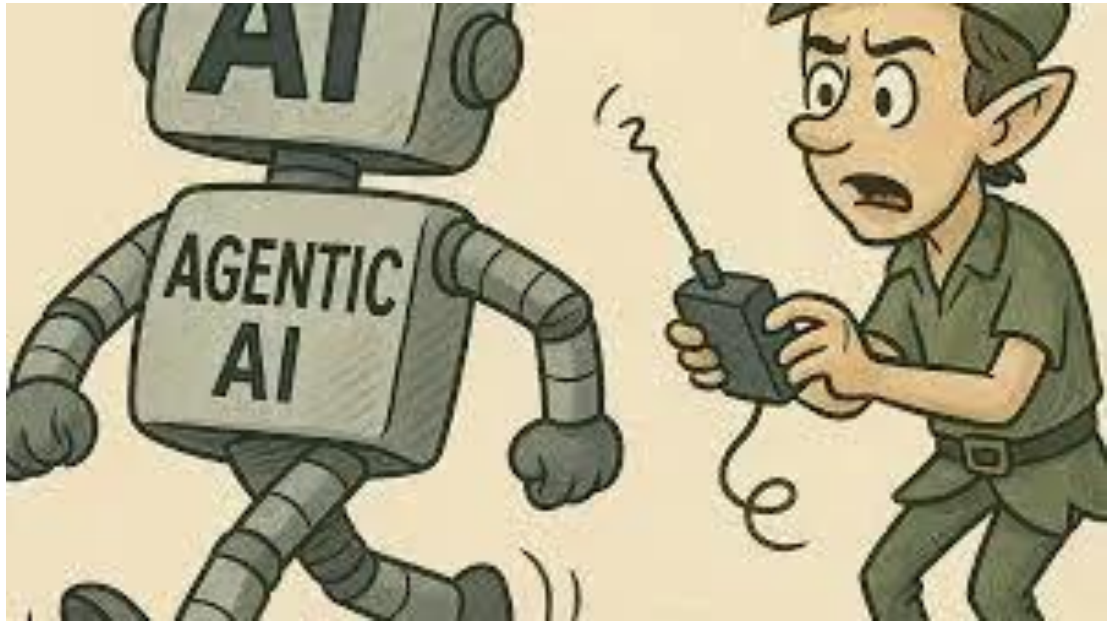


Autonomous AI Agent valt onder artikel 6:170 BW

HOE NEEM JE VERANTWOORDELIJKHEID?

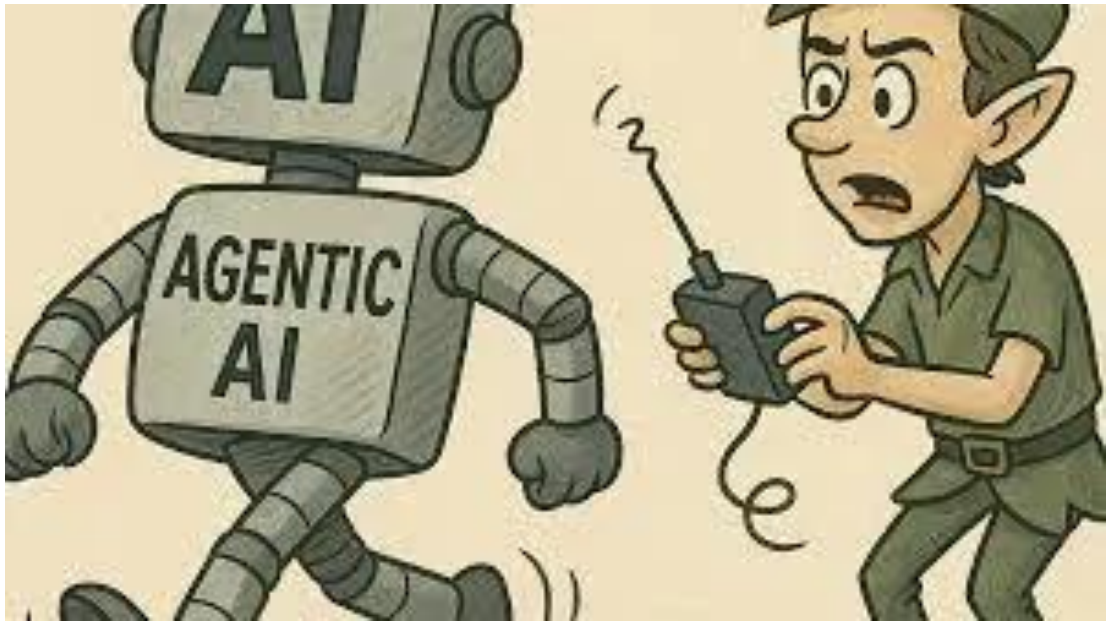
- Iedere AI Agent is onder supervisie van *iemand (de gebruiksverantwoordelijke)*
  - *Geldt dat niet ook voor iedere (junior) medewerker, iedere slagboom en pastamachine)*

- Onder welke voorwaarden accepteer *jij* die verantwoordelijkheid?



TEMMEN VAN DE AGENTS

- *iedere agent is van iemand*; er is altijd *iemand* accountable voor wat de agent doet (en wat deze operationeel; kost).
  - die accountability leidt er toe dat er eisen worden gesteld aan de agent en de context waarin deze functioneert - wie zou anders die verantwoordelijkheid willen hebben
- om de accountability invulling te kunnen geven is behoefte aan
  - *inzicht* in wat de agent zal gaan doen, doet en deed (welke acties/resultaten bij welke input)
  - mogelijkheid tot *ingrijpen* (bijsturen, tegenhouden, uitzetten)
  - *beperking* in wat een agent kan zien, doen en als resultaat veroorzaken; ook mogelijkheid tot vertragen (tot menselijke proporties) en pauzeren



Voorzicht, inzicht en toezicht

TEMMEN VAN DE AGENTS

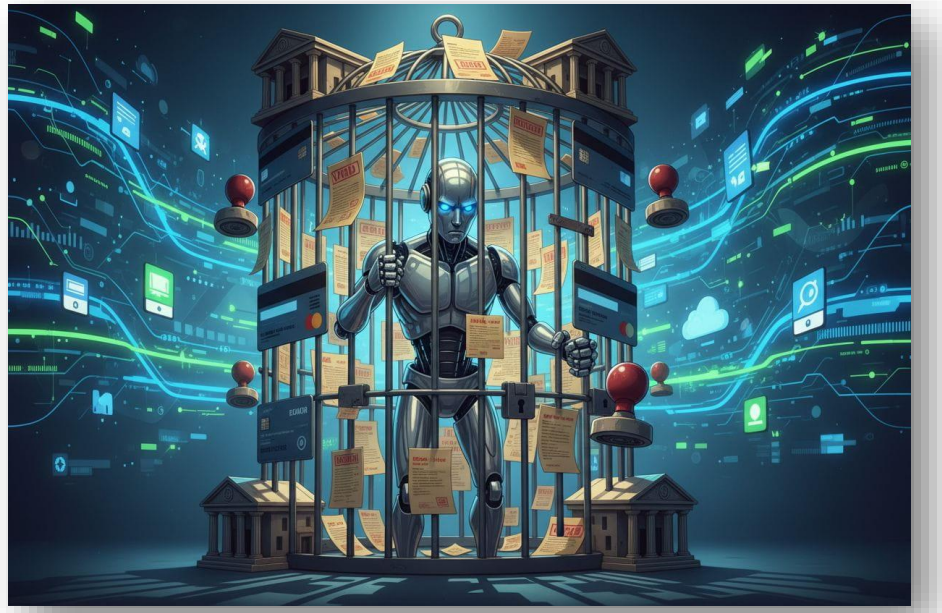
- inzicht in instructie / prompt en beschikbare tools / skills
- testen voordat de agent in echte actie gaat (en misschien ook wel testen in productie)
- observability - monitoring en real-time analyse/ anomaly en trend detectie
  - Nauwgezet monitoren welk netwerkverkeer plaatsvindt
- audit trail/ log
- guardian agents kunnen worden ingezet om de agent in real-time te controleren en over het gedrag te rapporteren



Ingrijpen, bijsturen, noodrem

TEMMEN VAN DE AGENTS

- human in the loop voor "belangrijke" beslissingen (de definitie daarvan moet helder zijn en hard geïmplementeerd worden: geen agent-actie mag de wereld ingaan zonder menselijke toestemming als het een belangrijke beslissing betreft
- waar mogelijk moeten acties terug te rollen zijn - en daar moet een mechanisme voor beschikbaar zijn
- er is een kill switch - de agent kan instantaan gestopt worden
- acties/resultaten die buiten de ingestelde bandbreedte vallen worden tegengehouden; een opdracht van een agent wordt altijd gecontroleerd tegen regels voordat deze ter uitvoering wordt aangeboden





Inbedden, begrenzen, keurslijf

TEMMEN VAN DE AGENTS



- heel strikt gedefinieerde set aan handelingsruimte geven: wat een agent domweg niet kan, kan hij ook niet doen.
- een agent heeft een "identity" en autorisaties die worden afgedwongen - bijvoorbeeld bij raadplegen van documenten, versturen van emails en uitvoeren van transacties (data-manipulatie, API aanroep)
  - least privilege: de agent mag zo min mogelijk
  - shortest privilege: de agent mag iets zo kort mogelijk (belangrijke privileges worden per keer verstrikt)
  - privileges worden gekoppeld aan taken / workflows (context-afhankelijk)
- agent mag niet code creëren en uitvoeren. Of (maar al een stuk spannender): alleen met strikte controles op de code en alleen in een speciale runtime omgeving mag een agent code uitvoeren
- agent heeft een beperkte set van acties (tools en skills) die in de "echte wereld" dingen kunnen doen
- als niet-bedoelde acties worden geconstateerd dan wordt de agent direct in quarantaine geplaatst en kan deze geen acties meer uitvoeren

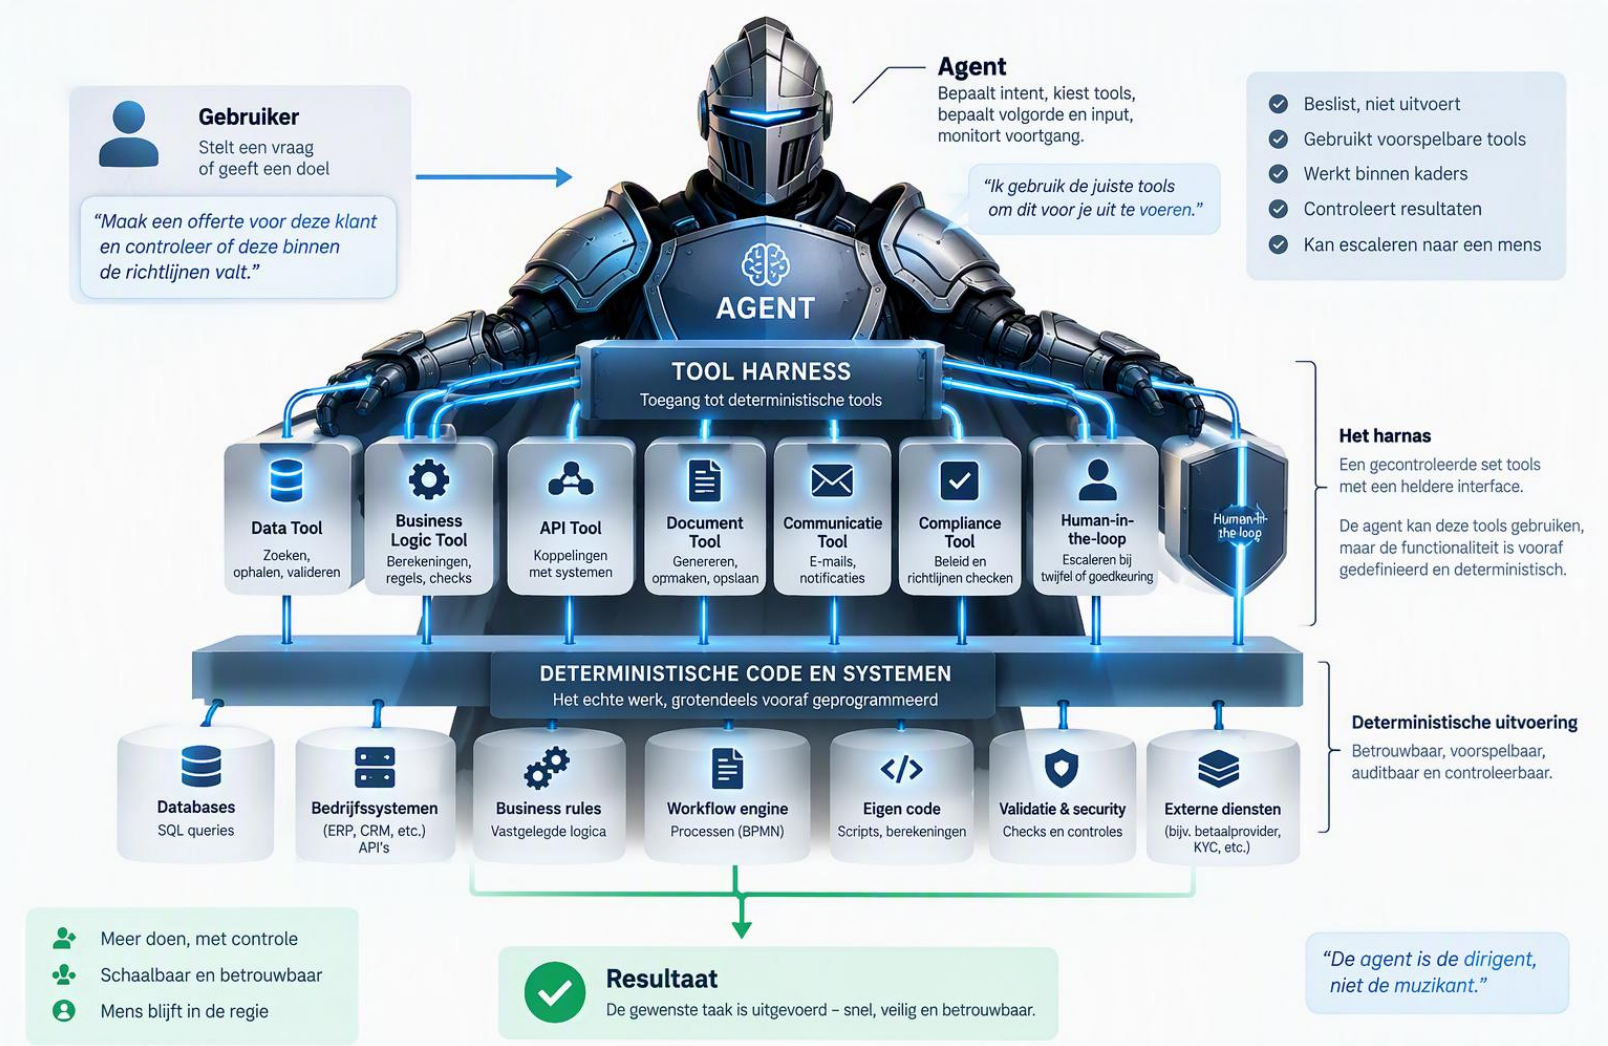
- Bij voorkeur wordt zoveel mogelijk functionaliteit hard, deterministisch gecodeerd; agent bepaalt vooral wanneer welke actie met welke input wordt geïnitieerd



Deterministische automatisering 'to the max'

AUTONOMIE ALLEEN WAAR NODIG

- Bij voorkeur wordt zoveel mogelijk functionaliteit hard, deterministisch gecodeerd; agent bepaalt vooral wanneer welke actie met welke input wordt geïnitieerd



Use it or lose it – de autonomie van de organisatie

AI AGENTS: ORGANISATORISCHE SKILL ATROFIE



Wat je uitbesteedt aan derden dreig je zelf te verleren

Wat AI Agents overnemen van je eigen medewerkers - kunnen en durven jullie zelf steeds minder

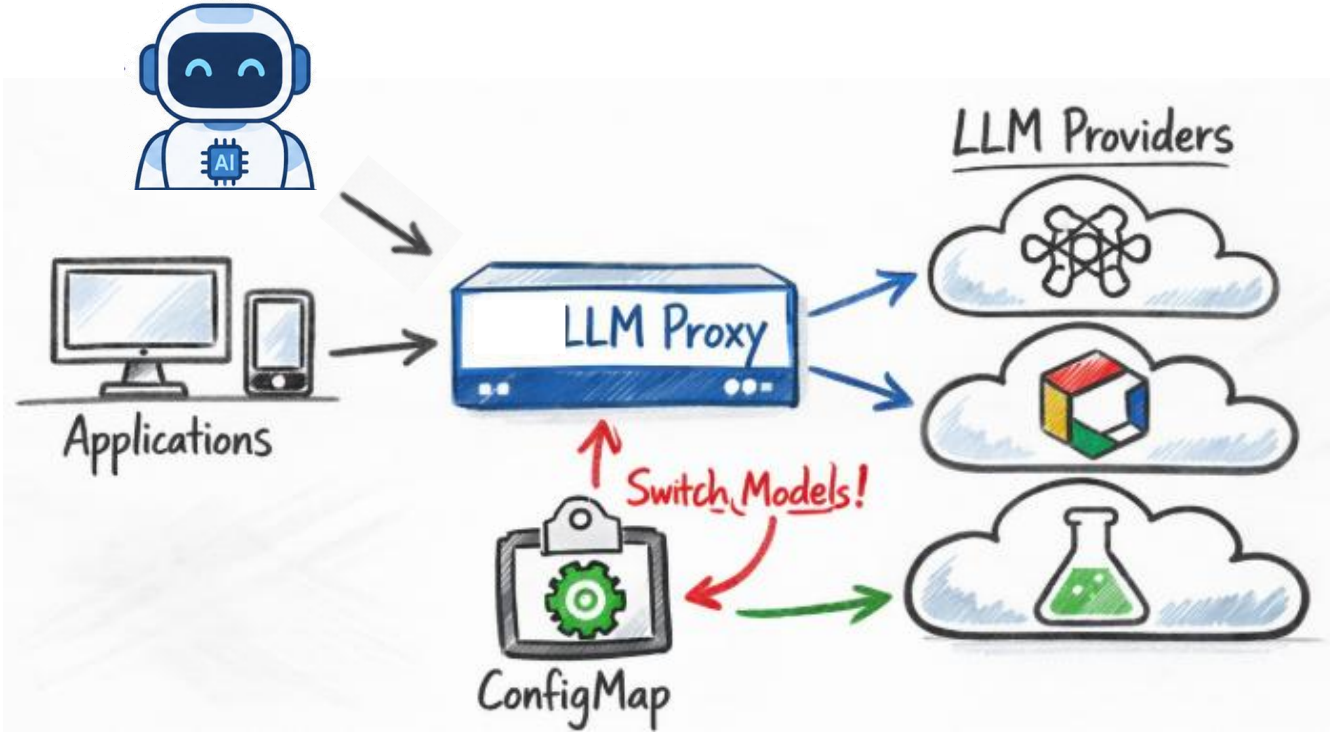
Muscle- & Brain-memory slijt

Wat heb je minimaal nodig om te instrueren, toezicht te houden, bij te sturen en eventueel te vervangen?

Autonomie betekent controle over je afhankelijkheden

DIGITALE AUTONOMIE VAN ORGANISATIE

- Maak je niet afhankelijk van één LLM leverancier
  - Kosten, continuïteit
- Maak je niet afhankelijk van 3rd party LLM leveranciers
  - Gebruik een self-hosted, open weights LLM
- Maak je niet afhankelijk van LLM & AI Agents
  - Kan het (ook) zelf?!



FUNDAMENT VOOR AUTONOME (AGENTIC) SYSTEMEN

- Autonomie - binnen grenzen



- Iedere agent rapporteert aan / valt onder een mens



- Verantwoordelijkheid kan je alleen nemen op voorwaarde van:
  - Beperken, Testen, Observeren, (kunnen) Ingrijpen



- Zo min mogelijk door LLM/Agent: dirigent – geen muzikant
  leve deterministische automatisering en “het harnas”



- Pas voor neveneffecten:
  ondermijning van autonomie

